

FICHA LABORATORIAL LAB3 - Análise de componentes principais

Ex1. Corre o código abaixo observando o propósito de cada instrução. Coloca a localização no teu computador do ficheiro 'MINISTsmall.p' que se encontra no Moodle

```
1 import numpy as np
2 from matplotlib import pyplot as plt
3 import pickle
4
```

```
1 s=pickle.load(open('/Users/gxufre/Dropbox/ARQUIV0/0
2 s.keys()
```

Visualizar os dados

```
1 digitos=dados["X"]
2 trueClass=dados["trueClass"]
3 f1=dados["foldTrain"]
4 f2=dados["foldTest"]
```

```
1 train3=digitos[:,(trueClass==3) & f1]
2 I3_8=np.reshape(train3[:,7],(28,28))
3 plt.imshow(255-I3_8, cmap='gray',interpolation=None)
```

```
1 I3_m=np.reshape(np.mean(train3,axis=1),(28,28))
2 plt.imshow(255-I3_m, cmap='gray',interpolation=None)
```

Ex.2. Corre o código abaixo observando o propósito de cada instrução

```
1 C0=np.cov(X[:,trueClass==0])
2 C1=np.cov(X[:,trueClass==1])
3 C2=np.cov(X[:,trueClass==2])
4 C3=np.cov(X[:,trueClass==3])
5 C4=np.cov(X[:,trueClass==4])
6 C5=np.cov(X[:,trueClass==5])
7 C6=np.cov(X[:,trueClass==6])
8 C7=np.cov(X[:,trueClass==7])
9 C8=np.cov(X[:,trueClass==8])
10 C9=np.cov(X[:,trueClass==9])
```

```
1 v=np.diag(C7)
2 z7=(v==0)*1
3 plt.imshow(1-z7.reshape((28,28)),cmap='gray')
```

```
1 z0=(np.diag(C0)!=0)
2 plt.imshow(z0.reshape((28,28)),cmap='gray')
```

```
1 z9=(np.diag(C9)!=0)
2 plt.imshow(z9.reshape((28,28)),cmap='gray')
```

Encontra uma justificação para as imagens obtidas.

Ex.3. Corre o código abaixo observando o propósito de cada instrução

Encontrar os valores e vetores próprios

```

1 X=digitos
2 Cx=np.cov(X) #no conjunto total de dados
3 (v,W)=np.linalg.eig(Cx) #v valores próprios, W vetores próprios

1 np.imag(v).max() #verificar máximo imaginário
2 v=v.real #descartar a parte imaginária dos valores próprios

1 idx=np.argsort(-v) #vamos ordenar os valores próprios por ordem decrescente
2 v=v[idx] #ordenar os valores próprios
3 W=W[:,idx] #ordenar os vetores próprios
4 W=W[:,v>=1e-10] #remover componentes com valores próprios próximo de zero
5 W=W.real #retirar a parte imaginária dos vetores próprios
6
7

1 plt.plot(np.log(v))

```

Observa a importância da aplicação do logaritmos e identifica o problema com o gráfico obtido. Apresenta uma solução para resolver o problema-

Ex. 4. Corre o código abaixo observando o propósito de cada instrução

Selecionar as componentes principais

```

1 v=v/np.sum(v) #Peso relativo de cada valor próprio
2 L=np.cumsum(v) #Peso relativo acumulado para cada valor próprio
3 plt.plot(L)

1 np.sum(L<=0.99) #número de componentes com 99% da variância
1 np.sum(L<=0.95) #número de componentes com 95% da variância

1 k=150

1 m=np.mean(X,axis=1)[: ,np.newaxis]
2 Xn=X-m

1 W2=W[:, :k]
2 Xp=np.dot(W2.T,X)
3 Xr=np.dot(W2,Xp)+m

1 x=Xr[:,4508].reshape(28,28)
2 print(x.min(),x.max())
3 x=x-x.min()
4 x=x/x.max()*255
5 plt.imshow(x.astype('uint8'), cmap='binary')

1 x=Xr[:,4508].reshape(28,28)
2 x=np.clip(x,0,255)
3 plt.imshow(x.astype('uint8'), cmap='binary')

```

Ex. 5. Corre o código abaixo observando o propósito de cada instrução

Usar o classificador k-NN

```
1 X1=X[:, f1]
2 X2=X[:, f2]
3 y1=trueClass[f1]
4 y2=trueClass[f2]
5 print(X1.shape,X2.shape)
```

Calcular as componentes principais

```
1 import scipy.linalg as la
2 Cx=np.cov(X1) #no conjunto de treino!!!!
3 u,V=la.eig(Cx)
4 u=u.real
5 V=V.real
```

```
1 idx=np.argsort(-u)
2 u=u[idx]
3 V=V[:,idx]
```

```
1 print(np.sum(u>=1e-6))
```

```
1 W=V[:, :664]
```

```
1 m=np.mean(X1,axis=1)[: ,np.newaxis]
2 X1n=X1-m
3 X1p=np.dot(W.T,X1n)
4
```

```
1 print(X1p.shape)
```

```
1 #Projetar nas componentes e fazer a mesma normalização para os dados de teste
2 X2n=X2-m
3 X2p=np.dot(W.T,X2n)
4 X2p=np.dot(S,X2p)
```

Ex. 6. Corre o código abaixo observando o propósito de cada instrução

```

1  from sklearn.neighbors import KNeighborsClassifier
2  from sklearn.metrics import confusion_matrix
3  from plotMatriz import plotMatriz
4
5  #Dados originais
6  |
7  knn=KNeighborsClassifier(n_neighbors=1).fit(X1.T,y1)
8  y2e=knn.predict(X2.T)
9  CM=confusion_matrix(y2,y2e)
10 plotMatriz(CM)
11 print(np.sum(y2!=y2e)/5000*100)

```

```

1  # Dados projetados nas componentes principais
2  knn_pca=KNeighborsClassifier(n_neighbors=1).fit(X1p.T,y1)
3  y2e=knn_pca.predict(X2p.T)
4  CM=confusion_matrix(y2,y2e)
5  plotMatriz(CM)
6  print(np.sum(y2!=y2e)/5000*100)

```

Ex. 7. Corre o código abaixo observando o propósito de cada instrução. Experimenta vários valores de número de componentes a utilizar e diferentes números de vizinhos no Knn. Tenta descobrir o conjunto de melhores pares nº de componentes/vizinhos para classificar os dígitos.

Fazer experiências

```

1  n_pca=???
2  vizinhos=???
3
4  W=V[:, :n_pca]
5  m=np.mean(X1,axis=1)[:, np.newaxis]
6  X1n=X1-m
7  X1p=np.dot(W.T,X1n)
8  X2n=X2-m
9  X2p=np.dot(W.T,X2n)
10
11 knn_pca=KNeighborsClassifier(n_neighbors=vizinhos).fit(X1p.T,y1)
12 y2e=knn_pca.predict(X2p.T)
13 CM=confusion_matrix(y2,y2e)
14 plotMatriz(CM)
15 print(np.sum(y2!=y2e)/5000*100)

```